

Знакомство с платформой для анализа данных Deductor часть2

1. Цель работы

Целью работы является знакомство студентов с аналитической платформой Deductor и приобретение навыков бизнес-анализа и визуализации данных с использованием данной среды.

2. Теоретическая часть

2.1 Описание платформы

Аналитическая платформа (АП) – это комплекс программных продуктов, связанных единой архитектурой. АП относятся к группе программных продуктов и технологий под общим названием Business Intelligence² и автоматизируют функции анализа бизнеса и поддержки принятия решений. Подобные системы стали появляться на мировом рынке информационных технологий в 80-90 годах прошлого столетия.

АП «Deductor», разработанная компанией BaseGroup Labs, является одной из лучших отечественных разработок в данной области.

Технологии и методики анализа данных, реализованные в этой платформе, позволяют на базе единой архитектуры пройти все этапы построения аналитической системы: начиная от создания хранилища данных и заканчивая построением моделей.

В ней сосредоточены самые современные методы извлечения, очистки, манипулирования и визуализации данных. С применением АП «Deductor» становятся доступными механизмы моделирования, прогнозирования, кластеризации, поиска закономерностей и многие другие технологии обнаружения знаний (Knowledge Discovery in Databases), добычи данных (Data Mining) и многомерного анализа (OLAP).

2.2 Возможности платформы

«Deductor» предназначен для решения широкого спектра задач, прикладная область значения не имеет, т.к. механизмы, реализованные в АП, с успехом применяются на финансовых рынках, в страховании, торговле, телекоммуникациях, промышленности, медицине, маркетинге и других сферах деятельности.

Рассмотрим наиболее популярные задачи, решаемые при помощи «Deductor»:

– *Создание систем отчетности.* Содержащиеся в хранилище данные можно просматривать, используя различные визуализаторы, например, OLAP кубы, таблицы, диаграммы, гистограммы.

– *Data Mining проекты.* Data Mining переводится как «добыча» или «раскопка данных». Это процесс обнаружения в сырых данных ранее неизвестных, нетривиальных, практически полезных и доступных интерпретации знаний, необходимых для принятия решений в различных областях человеческой деятельности. Он может применяться везде, где возникает потребность в глубоком анализе данных, но чаще всего речь идет об анализе коммерческой информации.

Некоторые задачи, решаемые при помощи методов Data Mining:

- анализ и управление рисками;
- сегментация клиентов, продуктов, услуг;
- определение особенностей поведения клиентов;

- промышленная диагностика, обнаружение источников и причин возникновения дефектов;
- идентификация критических ситуаций;
- оценка кредитоспособности физических и юридических лиц и многое другое.

– *Механизмы очистки данных.* На практике исходные данные чаще всего бывают «сырыми». Очищенные данные содержат наиболее ценную для анализа информацию, из которой исключены противоречивые и дублирующиеся данные, устранены аномалии и шумы. Во многих случаях достаточно провести только очистку данных, и выводы будут очевидны. Кроме того, очистка данных позволяет получить лучшие результаты при дальнейшем построении моделей.

– *Прогнозирование.* Это одна из самых востребованных задач анализа. В Deductor включены механизмы построения прогностических моделей, в том числе с использованием самообучающихся алгоритмов. Достаточно построить модель, прогнозирующую изменение на 1 шаг, и автоматически использовать ее на произвольное количество отсчетов вперед. Это позволяет получать качественные прогнозы, способные подстраиваться под изменяемую ситуацию.

– *Моделирование.* Построение моделей – универсальный способ анализа. В большинстве случаев при исследовании процесса или объекта мы строим его модель, но не всегда эта модель формализована, т.е. описана таким образом, чтобы ею мог воспользоваться другой человек, подавая свои входные данные и получая результат. В Deductor основной акцент сделан на самообучающиеся методы и машинное обучение. Такие алгоритмы являются универсальными, решающими большой спектр задач, и при этом просты в применении. Полученные результаты можно просмотреть в виде таблиц, кубов, карт, деревьев и прочее.

– *Анализ «Что,если...?».* При принятии управленческих решений полезным инструментом является сценарное моделирование «Что, если...?», которое позволяет моделировать будущие показатели деятельности с учетом имеющихся взаимосвязей. В частности, моделирование «Что, если...?» предназначено для анализа влияния исходных показателей на целевой показатель. Для реализации этого механизма в Deductor существует специальный визуализатор. При этом способ построения модели значения не имеет, работа со всеми алгоритмами производится одинаково. Результаты анализа можно просмотреть как в табличном, так и графическом виде.

2.3 Состав системы

«Deductor» состоит из пяти частей, показанных ниже на рисунке.



Состав АП «Deductor»

Deductor Studio является аналитическим ядром всей платформы, основанном на работе следующих механизмов:

- мастера импорта исходного набора данных;
- мастера обработки;
- мастера визуализации;
- мастера экспорта полученных данных.

То есть реализованные в Studio механизмы позволяют в рамках единого процесса пройти весь цикл анализа данных – получить исходную информацию из стороннего источника (хранилище данных Deductor Warehouse, промышленные СУБД, текстовые файлы, офисные приложения, 1С:Предприятие и прочее), обработать эту информацию, отобразить полученные результаты разными способами (например, с помощью таблиц, диаграмм, карт и т.п.) и экспортировать их (форматы Microsoft Excel, Microsoft Word, HTML, XML и др.).

Используется аналитиками-экспертами, которые занимаются созданием сценариев обработки.

Deductor Warehouse - это хранилище данных, содержащее в себе всю информацию, необходимую для анализа конкретной предметной области.

Использование Deductor Warehouse позволяет обеспечить:

- удобный доступ к данным;
- высокую скорость их обработки;
- непротиворечивость информации;
- централизованное хранение;
- поддержку процесса анализа данных.

От пользователя не требуется знание структуры хранения данных и языка запросов, для начала работы с хранилищем необходимо вызвать мастер импорта и выбрать интересующую его информацию.

Загрузка данных в Warehouse производится при помощи Deductor Studio либо Server. Хранилище строится на базе одной из трех СУБД: Oracle, MS SQL или Firebird.

Deductor Client – это динамическая библиотека для удаленной работы с Deductor Server. Обеспечивает доступ к серверу из сторонних приложений и управление его работой.

Deductor Viewer является рабочим местом конечного пользователя. У пользователей должна быть возможность просмотра полученных данных и настройки способа отображения, возможность экспорта их в офисные программы и другие форматы, а также им должна быть доступна функция печати необходимых сведений.

Еще одна важная функция Viewer – разграничения прав доступа к данным, т.е. пользователь может получить информацию, разрешенную ему в виде отчетов, при этом, не имея прав на получение новых данных.

Deductor Server – это служба, позволяющая осуществлять удаленную аналитическую обработку данных.

Использование сервера является оптимальным для корпоративной среды, что подтверждено следующими преимуществами:

- простота интеграции, т.к. удаленный доступ к нему осуществляется с помощью специальной бесплатно распространяемой библиотеки Deductor Client;
- удаленный доступ позволяет взаимодействовать с сервером как в локальной сети, так и через Интернет (по протоколу TCP/IP). Также Server позволяет автоматически восстанавливать соединения с базами данных при их обрыве и отключать «зависшие» сессии;

- высокая производительность и оптимальное использование оборудования достигается за счет многопоточной обработки, встроенных механизмов балансировки нагрузки, переноса на высокопроизводительный сервер наиболее ресурсоемких операций, кэширования загруженных ранее проектов, что также значительно повышает скорость аналитической обработки;
- удобство администрирования достигается за счет функции протоколирования, позволяющей фиксировать ход выполнения работ, возникающие ошибки, анализировать причины возникновения ошибок и производительность системы. Кроме того, в Deductor Server встроен планировщик заданий.


«Deductor» является идеальной платформой для создания систем поддержки принятия решений.

В «Deductor» используются мощные технологии анализа данных, но при этом акцент сделан на самообучающиеся методы, что позволяет строить системы, способные реагировать на изменение ситуации.

Объединение всех описанных выше механизмов в рамках единой программы обеспечивает принципиально новое качество – уменьшается время создания законченных решений, упрощается интеграция с другими приложениями, увеличивается производительность. Все это сочетается с гибкостью и простотой использования.

Платформа позволяет минимизировать требования к обучению персонала, поскольку все необходимые операции выполняются автоматически при помощи подготовленных ранее сценариев обработки.

2.4 Схема работы Deductor Studio




3. Подготовка к выполнению лабораторной работы

3.1 Установка ПО


3.1.1 Скачайте архив с установочным файлом Deductor Studio Academic по ссылке <https://basegroup.ru/deductor/download>. Разработчик указывает, что данное ПО работает только на Windows XP, Vista, 7, 8 и выше.

3.1.2 Извлеките из архива установочный файл и кликните по нему, чтобы начать установку.


3.1.3 Вам откроется Мастер установки. Чтобы продолжить установку, нажмите «Далее».



3.1.4 Прочитайте лицензионное соглашение. Чтобы продолжить установку, отметьте поле «Я принимаю условия соглашения» и нажмите «Далее».




3.1.5 Введите Ваше имя и фамилию в соответствующее поле. В качестве организации укажите «МГТУ им. Баумана». На скриншоте ниже указаны имя и фамилия другого пользователя в качестве примера. Использовать именно их необязательно. После заполнения полей нажмите «Далее».




The screenshot shows a window titled "Установка — Deductor Academic". The main heading is "Информация о пользователе" (User Information), with a subtext "Пожалуйста, введите данные о себе." (Please enter your data). There are two input fields: "Имя и фамилия пользователя:" (User name and surname) containing "Артём Волков" and "Организация:" (Organization) containing "МГТУ им. Баумана". At the bottom, there are three buttons: "< Назад" (Back), "Далее >" (Next), and "Отмена" (Cancel). The "Далее >" button is highlighted with a blue border.

3.1.6 Выберите папку установки программы. Мастер установки по умолчанию укажет путь к рекомендуемому месту установки. Если данная папка Вас не устраивает, то место установки можно поменять. Для этого необходимо нажать «Обзор», выбрать необходимую папку в проводнике и нажать «ОК». На скриншоте ниже указана папка установки в качестве примера. Использовать именно её необязательно. После выбора места установки программы нажмите «Далее».




The screenshot shows a window titled "Установка — Deductor Academic". The main heading is "Выбор папки установки" (Select installation folder), with a subtext "В какую папку Вы хотите установить Deductor Academic?" (In which folder do you want to install Deductor Academic?). A folder icon is shown next to the text "Программа установит Deductor Academic в следующую папку." (The program will install Deductor Academic in the following folder.). Below this, it says "Нажмите «Далее», чтобы продолжить. Если Вы хотите выбрать другую папку, нажмите «Обзор»." (Click "Next" to continue. If you want to choose another folder, click "Browse"). There is an input field containing "C:\Program Files\Deductor" and a button labeled "Обзор..." (Browse...). At the bottom, there is a note: "Требуется как минимум 1,6 Мб свободного дискового пространства." (At least 1.6 Mb of free disk space is required.). At the bottom of the window, there are three buttons: "< Назад" (Back), "Далее >" (Next), and "Отмена" (Cancel). The "Обзор..." button is highlighted with a blue border.


3.1.7 Выберите, какие компоненты должны быть установлены. Для выбора Вы можете пользоваться выпадающим списком, а также можно поставить «галочку» напротив тех компонентов, которые необходимо установить. Для успешного выполнения лабораторной работы необходимо отметить «галочкой» все компоненты – так, как указано на скриншоте ниже. Если на Вашем компьютере не хватает места на диске для установки данных компонентов, то необходимо прервать установку, освободить требуемое для установки место и вернуться в Мастер установки. После выбора компонентов нажмите «Далее».




3.1.8 Выберите папку в меню «Пуск» для создания ярлыков. Мастер установки по умолчанию укажет путь к рекомендуемому месту создания. Если данная папка Вас не устраивает, то место создания можно поменять. Для этого необходимо нажать «Обзор», выбрать необходимую папку в проводнике и нажать «ОК». На скриншоте ниже указана папка создания по умолчанию. Использовать именно её необязательно. После выбора места создания ярлыков нажмите «Далее».




3.1.9 Выберите дополнительные задачи, которые необходимо выполнить. Для выбора поставьте «галочку» в поле напротив описания задачи, которую необходимо выполнить. На скриншоте указан выбор задач по умолчанию, выбирать именно так необязательно. После выбора дополнительных задач, нажмите «Далее».




3.1.10 Всё готово к установке. Убедитесь, устраивают ли Вас опции установки, выбранные в предыдущих пунктах. Для этого прочитайте информацию в приведенном списке. Если Вас всё устраивает, нажмите «Установить» и переходите к следующему пункту, иначе – нажмите «Назад» и измените опции установки.



3.1.11 Дождитесь окончания установки. Если вы хотите запустить Deductor Academic сразу после закрытия Мастера установки, отметьте «галочкой» соответствующий пункт. Для окончания установки и закрытия Мастера установки нажмите «Завершить».




3.1.12 Для открытия пользуйтесь ярлыком или DStudio.exe, расположенном в <место установки программы>\Deductor\Bin. Перед запуском программы сначала Вам будет показываться окно «О программе», показанное на скриншоте ниже. Для закрытия данного окна и открытия стартовой страницы Deductor Academic нажмите «ОК».




4. Ход выполнения лабораторной работы

4.1 Знакомство с АП«Deductor»


После запуска «Deductor Studio Academic» появится главное окно программы.




4.1.1 Для начала работы необходимо создать новый сценарий, воспользуемся для этого мастером импорта (кнопка в левой части главного окна либо клавиша F6).




4.1.2 В качестве типа источника данных выберите текстовый файл




4.1.3 Выберите файл Vote.txt




4.1.4 В качестве параметров импорта оставьте параметры, установленные по умолчанию, как указано на скриншоте ниже.





4.1.5 В качестве параметров импорта файла с разделителями оставьте параметры, установленные по умолчанию, как указано на скриншоте ниже.




4.1.6 В качестве параметров столбцов оставьте параметры, установленные по умолчанию.




4.1.7 Запустите процесс импорта данных из текстового файла нажатием кнопки «Пуск» и дождитесь его успешного завершения.




4.1.8 В качестве способов отображения данных выберите «Таблица», «Статистика» и «Сведения».




4.1.9 Укажите имя «VoteResults». Описание данных можно не заполнять.




Выполнив вышеуказанные действия по импорту данных, на панели «Сценарии» мы получим новый узел, с заданными именем, меткой и описанием.




- 4.1.10 Кликните правой кнопкой мыши по узлу и переименуйте его в «Результаты голосования».
- 4.1.11 Перейдя на вкладку «Статистика», Вы увидите подробные статистические данные по каждому проекту, по которому проводилось голосование.




- 4.1.12 Дважды кликнув по гистограмме, Вы увидите её более подробный вид:




4.2 Изучим возможности мастера обработки




- 4.2.1 После его запуска появится список возможных способов обработки данных. Выберите «Фильтрация».



4.2.2 Посмотрим, как голосовали демократы. Для этого настроим условия фильтрации следующим образом:




4.2.3 Запустите фильтрацию данных и дождитесь её выполнения.



4.2.4 В качестве способов отображения данных выберите те же: «Таблица», «Статистика», «Сведения».

4.2.5 Назовите «DemocratVotes». В качестве метки напишите «Только демократы». В описании напишите «Результаты голосования демократов».

4.2.6 Вы получили фильтр. Таблица была отфильтрована, статистика подкорректирована. Можете её поизучать.



4.2.7 Фильтр можно деактивировать, кликнув по нему правой кнопкой мыши и выбрав соответствующий пункт. Тогда Вы вернётесь к исходной неотфильтрованной таблице. Также между узлами можно просто переключаться, дважды кликая по ним.

4.3 Спектральная обработка

Спектральная обработка предназначена для сглаживания и очистки от шумовой составляющей рядов данных. В узле «Редактирование выбросов» имеется алгоритм для коррекции выбросов и экстремальных значений с помощью робастной фильтрации (Сглаживать...), однако алгоритмические возможности этого узла намного шире. Для этих целей в узле используются два подхода: преобразование Фурье и вейвлеты.

Для сглаживания данных первым методом используется низкочастотная фильтрация с использованием быстрого преобразования Фурье. При этом задается верхнее значение полосы пропускаемых частот, т.е. отсекается все, что выше данного порога. Высокочастотная составляющая временного ряда соответствует резко изменяющимся данным, а низкочастотная – плавно изменяющимся.

При подавлении шумов на основе анализа распределения составляющих Фурье спектра на выход фильтра пропускаются спектральные составляющие, превышающие некоторый порог, рассчитанный по эмпирическим формулам в соответствии с заданным критерием степени вычитания шума. Чем больше требуется сгладить данные, тем меньше должно быть значение полосы. Однако слишком узкая полоса может привести к потере полезной информации. Следует заметить, что этот алгоритм наиболее эффективен, если анализируемые данные являются суммой полезного сигнала и белого шума.

Второй способ сглаживания – это вейвлет-преобразование. Если выбран данный метод, то необходимо задать глубину разложения и порядок вейвлета. Глубина разложения определяет «масштаб» отсеиваемых деталей: чем больше эта величина, тем более «крупные» детали в исходных данных будут отброшены. При достаточно больших значениях параметра (порядка 7-9) выполняется не только очистка данных от шума, но и их сглаживание («обрезаются» резкие выбросы). Использование слишком больших значений


глубины разложения может привести к потере полезной информации из-за слишком большой степени «огрубления» данных. Порядок вейвлета определяет гладкость восстановленного ряда данных: чем меньше значение параметра, тем ярче будут выражены «выбросы», и, наоборот, при больших значениях параметра «выбросы» будут сглажены.

Для вычитания шума снова используется преобразование Фурье. Шумы в данных не только скрывают общую тенденцию, но и проявляют себя при построении модели прогноза. Из-за них модель может получиться с плохими обобщающими качествами. При выборе режима очистки от шумов необходимо задать степень вычитания шума: малую, среднюю или большую. При использовании вычитания шума следует соблюдать осторожность, так как реализованный здесь эвристический алгоритм (также как и первый на основе преобразования Фурье) гарантирует удовлетворительный результат лишь при выполнении двух условий:

- дисперсия шума значительно меньше энергии полезного сигнала;
- шум имеет нормальное распределение.


4.3.1 С помощью Мастера импорта импортируйте файл Trade.txt. В качестве разделителей целой и дробной части числа укажите «.» (точку). В качестве способов отображения данных выберите «Таблица» и «Диаграмма». Остальные параметры оставьте по умолчанию. Выполните импорт. Укажите имя «Trade», метка - «Продажи». Описание можно не заполнять.

4.3.2 Диаграмма должна выглядеть так:




4.3.3 Выполните спектральную обработку.


4.3.3.1 Запустите Мастер обработки и выберите Спектральную обработку. Выберите «Количество», сглаживание данных путём Фурье-преобразования с полосой пропускания 15. Выполните обработку. В качестве способов отображения данных выберите «Таблица» и «Диаграмма». Остальные параметры, включая имя и метку оставьте установленными по умолчанию.




4.3.3.2 Диаграмма должна выглядеть так:



4.3.4 Теперь примените к исходным данным «Продажи» спектральную обработку с применением вейлвет-преобразования с глубиной разложения 3 и порядком 6. Диаграмма должна выглядеть так:



4.3.5 Наконец, примените к «Продажи» Фурье-преобразование с большой степенью вычитания шума. Диаграмма должна выглядеть так:



4.4 Прогнозирование умножения с помощью нейронных сетей

4.4.1 Рассмотрим прогнозирование с помощью нейронных сетей на примере прогнозирования результата умножения двух чисел – файл «Произведение.txt». В нем содержится таблица со следующими полями: «АРГУМЕНТ1», «АРГУМЕНТ2» – множители, «ПРОИЗВЕДЕНИЕ» – их произведение. Причем произведение некоторых чисел пропущено в обучающей выборке, например, $7 \times 7 = 49$. Импортировав данные из файла, можно посмотреть результат умножения, используя таблицу.

4.4.2 Необходимо построить модель прогноза умножения, подавая на вход которой два множителя получать на выходе их произведение.

4.4.2.1 Для этого необходимо после импорта открыть мастер обработки и выбрать в качестве обработки нейронную сеть и перейти к следующему шагу мастера.

4.4.2.2 Далее необходимо установить назначение полей «АРГУМЕНТ1» и «АРГУМЕНТ2» как входные, а поле «ПРОИЗВЕДЕНИЕ» – как выходное и задать тип данных как «Целый» у всех трёх полей.

4.4.2.3 На следующем шаге предлагается настроить разбиение исходного множества данных на обучающее и тестовое. Здесь необходимо указать способ разбиения исходного множества данных «Случайно» и поставить обучающее множество размером 100 %, так как выборка слишком мала.

4.4.2.4 Далее необходимо указать функцию активации, количество скрытых слоев, и количество нейронов в слое. Данные необходимо подбирать экспериментально, так как большое количество нейронов и слоев, может сильно замедлить процесс обучения. Эмпирически были выставлены настройки, показанные на скриншоте ниже.


4.4.2.5 Выберите алгоритм обучения и его параметры. Выберите Resilient Propagation, шаг спуска = 0,5, шаг подъема = 1,2.

4.4.2.6 Далее настроим условия остановки обучения. Пусть пример считаем распознанным, если ошибка меньше 0,005. Также укажем условие остановки обучения при достижении эпохи 100000.


4.4.2.7 Следующий шаг мастера предлагает запустить процесс обучения и наблюдать в процессе обучения величину ошибки, а также процент распознанных примеров.

4.4.2.8 После обучения сети, в качестве визуализаторов выберем варианты: «Диаграмма», «Диаграмма рассеяния», «Граф нейросети», «Что-если». На диаграмме в качестве меток столбцов отметьте ПРОИЗВЕДЕНИЕ и ПРОИВЗЕДЕНИЕ_OUT.

4.4.2.9 Результаты наглядно видны на диаграмме рассеяния, которая показывает рассеяние прогнозируемых данных относительно эталонных. По диаграмме можно судить, что сеть обучена недостаточно хорошо, из-за малого объема обучающей выборки.



4.4.3 Также можно сравнить эталонные данные с прогнозируемыми, выбрав на обычной диаграмме два поля – «ПРОИЗВЕДЕНИЕ» и «ПРОИЗВЕДЕНИЕ_OUT». 3D-отображение включается через контекстное меню по нажатию правой кнопкой мыши. Если масштабировать диаграмму и включить отображение меток, то можно увидеть достаточно большую ошибку, но на цели этого задания она сказываться не будет.




4.4.4 Визуализатор «Что-если» позволит провести эксперимент, введя любые значения множителей АРГУМЕНТ1 и АРГУМЕНТ2 и рассчитав результат их произведения. Попробуем ввести аргументы, которые отсутствуют в обучающей выборке, например, 7х7. Сеть обучена достаточно точно, так как получен верный результат несмотря на то, что сеть никогда не видела такую комбинацию аргументов.

Поле	Значение
Входные	
12 АРГУМЕНТ1	7
12 АРГУМЕНТ2	7
Выходные	
12 ПРОИЗВЕДЕНИЕ	49

4.4.5 Далее введем в окно «Что-Если» аргументы, которые как следует из диаграммы и диаграммы рассеивания, имели большую ошибку. Как видим, данные диаграммы верны относительно ошибки.

Поле	Значение
Входные	
12 АРГУМЕНТ1	8
12 АРГУМЕНТ2	8
Выходные	
12 ПРОИЗВЕДЕНИЕ	63

4.4.6 Вид построенной сети можно посмотреть, выбрав визуализатор «Граф нейронной сети».



Данный пример показал, как можно построить модель прогноза, используя нейронную сеть. Пример показал, что для построения нет необходимости в строгой математической спецификации модели, что особенно ценно при анализе плохо формализуемых процессов. А большинство бизнес задач плохо формализуется. Это означает, что наличие достаточно развитых и удобных инструментальных программных средств позволяет аналитику при построении модели прогнозируемого процесса руководствоваться такими понятиями, как опыт и интуиция.

Настройки мастера позволяют увидеть широкие возможности Deductor Studio касательно структуры сети, способов обучения и т.д. Аналитик предоставляется широкие возможности по настройке нормализации столбцов, разбиения данных на обучающее и тестовое множество, определения структуры сети, количества слоев и нейронов в каждом слое, выборе функции активации и ее параметров, выборе различных алгоритмов обучения и настройки их параметров.

Все это позволяет построить модель, описывающую практически любые закономерности. Также было показано, как можно спрогнозировать результат, введя любые значения входных факторов, используя визуализатор «Что-если». Качество подготовки данных для модели, а также качество самой модели аналитик может оценить разными способами: посмотреть диаграмму рассеяния, провести ряд экспериментов при помощи «Что-если», построить гистограмму распределения ошибки и т.п.


4.5 Прогнозирование данных на основе временного ряда

Прогнозирование результата на определенное время вперед, основываясь на данных за прошедшее время – задача, встречающаяся довольно часто (к примеру, перед большинством торговых фирм стоит задача оптимизации складских запасов, для решения которой требуется знать, чего и сколько должно быть продано через неделю, и т.п.; задача предсказания стоимости акций какого-нибудь предприятия через день и т.д. и другие подобные вопросы). Deductor Studio предлагает для этого инструмент «Прогнозирование».

Прогнозирование появляется в списке мастера обработки только после построения какой-либо модели прогноза: нейросети, линейной регрессии и т.д. Прогнозировать на несколько шагов вперед имеет смысл только временной ряд (к примеру, если есть данные по недельным суммам продаж за определенный период, можно спрогнозировать сумму продаж на две недели вперед). Поскольку при построении модели прогноза необходимо учитывать много факторов (зависимость результата от данных день, два, три, четыре назад), то методика имеет свои особенности. Покажем ее на примере.


4.5.1 У аналитика имеются данные о месячном количестве проданного товара за несколько лет. Ему необходимо, основываясь на этих данных, сказать, какое количество товара будет продано через неделю и через две. Исходные данные по продажам находятся в уже знакомом файле «Trade.txt». Выполним импорт данных из файла. В качестве разделителей целой и дробной части числа не забудьте указать «.» (точку).

4.5.2 После импорта данных воспользуемся диаграммой для их просмотра. Щелкнув правой кнопкой мыши по импортированному файлу, Вы можете запустить Мастер визуализации и выбрать там диаграмму. На ней видно, что данные содержат аномалии (выбросы) и шумы, за которыми трудно разглядеть тенденцию.



4.5.3 Поэтому перед прогнозированием необходимо удалить аномалии и сгладить данные. Сделать это можно при помощи рассмотренной ранее спектральной обработки. Запустим мастер обработки, выберем в качестве обработки данных спектральную обработку и перейдем на следующий шаг мастера. Следующий шаг отвечает за удаление аномалий из исходного набора. Выберем поле для обработки «КОЛИЧЕСТВО» и укажем для него вычитание шума (степень вычитания – малая).

4.5.4 На следующем шаге запустим обработку, нажав на «пуск» и посмотрим полученный результат.



Видно, что данные сгладились, аномалии и шумы исчезли. Также видна тенденция. Теперь перед аналитиком встает вопрос, а как, собственно, прогнозировать временной ряд. В предыдущем примере мы сталкивались с ситуацией, когда есть входные столбцы -

факторы и есть выходной столбец – результат. В данном случае столбец один. Строить прогноз на будущее необходимо, основываясь на данных прошлых периодов. Предполагается, что количество продаж на следующий месяц зависит от количества продаж за предыдущие месяцы. Входными факторами для модели могут быть продажи за текущий месяц, продажи за месяц ранее и т.д., а результатом должны быть продажи за следующий месяц. Здесь явно необходимо трансформировать данные к скользящему окну.

4.5.5 Запустим мастер обработки, выберем в качестве обработчика скользящее окно и перейдем на следующий шаг. Было решено строить прогноз на неделю вперед, основываясь на данных за 12, 11 месяцев назад, два месяца назад и месяц назад. Поэтому необходимо, назначив поле «КОЛИЧЕСТВО» используемым, выбрать глубину погружения 12. Тогда данные трансформируются к скользящему окну так, что аналитику будут доступны все требуемые факторы для построения прогноза.


4.5.6 Просмотреть полученные данные можно в виде таблицы. Как видно, теперь в качестве входных факторов можно использовать «КОЛИЧЕСТВО - 12», «КОЛИЧЕСТВО - 11» - данные по количеству 12 и 11 месяцев назад (относительно прогнозируемого месяца) и остальные необходимые факторы. В качестве результата прогноза будет указан столбец «КОЛИЧЕСТВО».

Таблица											
1 / 38											
Дата [Год + Месяц]	Количество-12	Количество-11	Количество-10	Количество-9	Количество-8	Количество-7	Количество-6	Количество-5	Количество-4	Количество-3	Количество
2001-M01	1194171,83234344	1046415,57493634	932948,696708493	876811,482945926	886363,954187957	953101,935969064	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226
2001-M02	1046415,57493634	932948,696708493	876811,482945926	886363,954187957	953101,935969064	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909
2001-M03	932948,696708493	876811,482945926	886363,954187957	953101,935969064	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601
2001-M04	876811,482945926	886363,954187957	953101,935969064	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	82741
2001-M05	886363,954187957	953101,935969064	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277
2001-M06	953101,935969064	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	29387
2001-M07	1054236,37323982	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	44722
2001-M08	1159298,78809065	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	05780
2001-M09	1238890,98359425	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	84579
2001-M10	1273087,82816098	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	48648
2001-M11	1257101,558226	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	69977
2001-M12	1202596,15186909	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	32695
2002-M01	1134278,9568601	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	93730
2002-M02	1082741,44116953	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	00246
2002-M03	1075589,0358277	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	84899
2002-M04	1129387,59940122	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	13984
2002-M05	1244722,39882958	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	19722
2002-M06	1405780,31724992	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	77669
2002-M07	1584579,56210144	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	1877669,89309596	82808
2002-M08	1748648,97195808	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	1877669,89309596	1982808,26969165	14966
2002-M09	1869977,75195024	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	1877669,89309596	1982808,26969165	2114966,94878914	44486
2002-M10	1932695,06215055	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	1877669,89309596	1982808,26969165	2114966,94878914	2244486,78162409	34062
2002-M11	1937300,2703798	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	1877669,89309596	1982808,26969165	2114966,94878914	2244486,78162409	2340625,9234106	38031
2002-M12	1900246,00967173	1848998,2271489	1813984,00300846	1819722,97428057	1877669,89309596	1982808,26969165	2114966,94878914	2244486,78162409	2340625,9234106	2380312,1698561	54751


4.5.7 Перейдем непосредственно к самому построению модели прогноза. Откроем мастер обработки и выберем в нем нейронную сеть. На втором шаге мастера, согласно с принятым ранее решением, установим в качестве входных поля «КОЛИЧЕСТВО-12», «КОЛИЧЕСТВО-11», «КОЛИЧЕСТВО-2» и «КОЛИЧЕСТВО-1», а в качестве выходного - «КОЛИЧЕСТВО». Остальные поля сделаем информационными.

4.5.8 Оставив остальные параметры построения модели по умолчанию, количество нейронов скрытого слоя поставим равным 5. Обучим нейросеть.

4.5.9 После построения модели для просмотра качества обучения представим полученные данные в виде диаграммы и диаграммы рассеяния. В мастере настройки диаграммы выберем для отображения поля «КОЛИЧЕСТВО» и «КОЛИЧЕСТВО_OUT» - реальное и спрогнозированное значение. Также необходимо построить граф нейросети и визуализатор «Что-если».



4.5.10 Диаграмма рассеяния более наглядно показывает качество обучения:




4.5.11 Нейросеть обучена, теперь осталось самое главное – построить требуемый прогноз.

4.5.11.1 Для этого открываем мастер обработки и выбираем появившийся теперь обработчик «Прогнозирование».


4.5.11.2 На втором шаге мастера предлагается настроить связи столбцов для прогнозирования временного ряда – откуда брать данные для столбца при очередном шаге прогноза. Мастер сам верно настроил все переходы, поэтому остается только указать горизонт прогноза (на сколько вперед будем прогнозировать) равным трем, а

также, для наглядности, необходимо добавить к прогнозу исходные данные, установив в мастере соответствующий флажок.

4.5.11.3 После этого необходимо в качестве визуализатора выбрать диаграмму прогноза, которая появляется только после прогнозирования временного ряда. В мастере настройки столбцов диаграммы прогноза необходимо указать в качестве отображаемого столбец «КОЛИЧЕСТВО». Теперь аналитик может дать ответ на вопрос, какое количество товаров будет продано в следующем месяце и даже два месяца спустя.



4.5.11.4 Масштабировав результат и включив метки правой кнопкой мыши, можно увидеть расчетные значения на 3 месяца вперед.



4.5.12 После завершения анализа данные можно экспортировать. Так как данная версия является бесплатной для образовательных целей, то данные можно выгрузить либо в текстовый файл, либо в собственный проект программы с расширением «*.ded». Мастер экспорта имеет точно такие же настройки, как и мастер импорта. Более того, если экспорт данных совершить в текстовый файл, то далее данные можно скопировать в файл табличного процессора Excel, и достаточно комфортно с ними работать.

Данный пример показал, как с помощью Deductor Studio прогнозировать временной ряд. При решении задачи были применены механизмы очистки данных от шумов, аномалий, которые обеспечили качество построения модели прогноза далее и соответственно достоверный результат самого прогнозирования количества продаж на три месяца вперед. Также был продемонстрирован принцип прогнозирования временного ряда – импорт, выявление сезонности, очистка, сглаживание, построение модели прогноза и собственно построение прогноза временного ряда, а также экспорт результатов во внешний файл.

4.6 Кластеризация с помощью самоорганизующихся карт Кохонена

Самоорганизующаяся карта Кохонена (англ. Self-organizing map - SOM) – соревновательная нейронная сеть с обучением без учителя, выполняющая задачу визуализации и кластеризации. Идея сети предложена финским учёным Т. Кохоненом. Является методом проецирования многомерного пространства в пространство с более низкой размерностью (чаще всего, двумерное), применяется также для решения задач моделирования, прогнозирования и др. Самоорганизующаяся карта состоит из компонентов, называемых узлами или нейронами. Их количество задаётся аналитиком. Каждый из узлов описывается двумя векторами. Первый – т. н. вектор веса m , имеющий такую же размерность, что и входные данные. Вторым — вектор g , представляющий собой координаты узла на карте. Обычно узлы располагают в вершинах регулярной решётки с квадратными или шестиугольными ячейками.

Самоорганизующаяся карта Кохонена является разновидностью нейронной сети. Она применяется, когда необходимо решить задачу кластеризации, т.е. распределить данные по нескольким кластерам. Алгоритм определяет расположение кластеров в многомерном пространстве факторов. Исходные данные будут относиться к какому-либо кластеру в зависимости от расстояния до него. Многомерное пространство трудно для представления в графическом виде. Механизм же построения карты Кохонена позволяет отобразить многомерное пространство в двумерном, которое более удобно и для визуализации, и для интерпретации результатов аналитиком. Также с помощью построенной карты Кохонена можно решить и задачу прогнозирования. В этом случае результирующее поле (то, которое необходимо спрогнозировать) в построении карты не участвует. После кластеризации, используя диаграмму «Что-если», можно провести эксперимент. Алгоритм определяет точку пространства, где расположены введенные для прогноза данные и к какому кластеру принадлежит данная точка, и подсчитывает среднее по результирующему полю всех точек этого кластера, что и будет результатом прогноза (для дискретных данных результатом прогноза является значение, больше всего встречающееся в результирующем поле всех ячеек кластера).

4.6.1 Рассмотрим механизм кластеризации путем построения самоорганизующейся карты, основываясь на типичных характеристиках цветков. Исходная таблица находится в файле примеров «Ирисы.txt». Она содержит следующие параметры цветов: «Длина чашелистика», «Ширина чашелистика», «Длина лепестка», «Ширина лепестка», «Класс». Задача состоит в том, чтобы определить по различным параметрам цветка его класс. Предполагается, что цветы одного класса имеют схожие параметры, поэтому они должны находиться в одном кластере.

4.6.2 Для начала необходимо импортировать данные из файла. После этого запустим, мастер обработки и выберем из списка метод обработки «Карта Кохонена». На втором шаге мастера настроим назначения столбцов. Укажем столбцу «Класс» назначение «Выходной», а остальным – «Входной». Т.е. на основе данных о цветке будем относить его к тому или иному классу.

4.6.3 На третьем шаге мастера необходимо настроить способ разделения исходного множества данных на тестовое и обучающее, а также количество примеров в том и другом множестве. Укажем, что данные обоих множеств берутся случайным образом, зададим размер тестового множества равным 10 примерам, путем изменения значения столбца «Размер в строках» строки «Тестовое множество».

4.6.4 Настройте параметры карты (количество ячеек по X и по Y, их форму) и параметры обучения (способ начальной инициализации, тип функции соседства, перемешивать ли строки обучающего множества и количество эпох, через которые необходимо перемешивание). Значения по умолчанию вполне подходят.


4.6.5 Необходимо настроить параметры остановки обучения. Оставим параметры по умолчанию.

4.6.6 Настраиваем остальные параметры обучения – способ начальной инициализации, тип функции соседства и также параметры кластеризации – автоматическое определение числа кластеров с соответствующим уровнем значимости либо фиксированное количество кластеров предоставляется возможность настроить интервалы обучения. Каждый интервал задается количеством эпох, радиусом обучения и скоростью обучения. Укажем фиксированное количество кластеров, равное трем.


4.6.7 Запускаем сам процесс обучения. Во время обучения можно посмотреть количество распознанных примеров и текущие значения ошибок.

4.6.8 После этого необходимо в списке визуализаторов выбрать появившуюся теперь «Карту Кохонена» для просмотра результатов кластеризации, а также визуализатор «Что-если» для прогнозирования класса цветка.

4.6.9 Далее, в мастере настройки отображения карты Кохонена необходимо указать, чтобы отображались все поля, также следует установить количество кластеров равным трем и поставить флажок «Границы кластеров».



4.6.10 После этого можно увидеть полученные результаты. Качество кластеризации можно оценить, просмотрев карту «Класс». На ней видно, что большинство цветов были классифицированы правильно. Заметим, что все цветы класса *Setosa* попали в один кластер. Это говорит о значительном отличии параметров цветов этого класса от других. Явное различие наблюдается по длине и ширине лепестка. То, что часть примеров *Virginica* попала в класс *Versicolor* и наоборот говорит о меньшем различии этих классов. На картах, в отличие от *Setosa* не видны резкие отличия параметров цветов этих двух классов. Этим как раз и объясняется «проникновение» некоторой части примеров в другой кластер.



4.6.11 Рассмотрим построенную таблицу «Что-Если». В верхней части таблицы отображаются входные поля, а в нижней – выходные и расчетные. Изменяя значения входных полей, пользователь дает команду на выполнение расчета и наблюдает за рассчитанными значениями выходов нейронной сети или дерева решений. Расчетные поля отличаются от выходных тем, что они не существуют в исходном наборе данных и были созданы в ходе обработки. Такими полями являются, например, «Номер ячейки» или «Номер кластера».

4.6.12 С помощью кнопки «Показать статистику» справа от таблицы можно вывести статистику по выделенному полю. Для непрерывных полей в ней отображается следующая информация: – «Минимум» – минимальное значение поля в выборке; – «Максимум» – максимальное значение поля в выборке; – «Среднее» – среднее по выборке значение поля; – «Стандартное откл.» – среднеквадратическое отклонение значений поля по выборке. Знание диапазона входных данных (минимума и максимума), на котором строилась модель, позволит определить область устойчивости системы. Очевидно, что, если подать на вход значения, существенно выходящие за диапазон, гарантировать правильную реакцию системы нельзя, и достоверность полученных данных может быть снижена. Если значение, присвоенное полю, выходит за границы диапазона, это поле окрашивается в красный цвет.

4.6.13 Как видно из таблицы «Что-если», даже данные отсутствующие в изначальной выборке определяются корректно.

Поле	Значение	Параметр	Значение
Входные		Минимум	0.1
9.0 Длина чашелист...	4.3	Максимум	2.5
9.0 Ширина чашелис...	2	Среднее	1.198666667
9.0 Длина лепестка	1	Стандартное откл.	0.7631607417
9.0 Ширина лепестка	0.1		
Выходные			
ab Класс	Iris-setosa		
Расчетные			
12 Номер ячейки	177		
9.0 Расстояние до ц...	0.168108093682723		
12 Номер кластера	2		
9.0 Расстояние до ц...	0.48877328909219		

Данный пример показал область применения самоорганизующихся карт. Изначально имелось многомерное (четырёхмерное) пространство входных факторов. Алгоритм представил его в двумерном виде, которое удобнее анализировать. Также исходные данные были отнесены к трем кластерам, по типу цветка – «Setosa», «Versicolour», «Virginica». Основным визуализатором после построения является «Самоорганизующаяся карта». Здесь в первую очередь следует обратить внимание на матрицу расстояний и проекцию Саммона. На них явно видны расстояния между отдельными ячейками карты, т.е. четкие границы различных скоплений данных. Мастер предоставляет широкий набор настройки параметров обучения: настройка нормализации столбцов, настройка разбиения на тестовое и обучающее множество, настройка условий останова обучения, настройка параметров карты и параметров обучения, настройка интервалов обучения. информация о задаче, то качество очистки данных можно увеличить на порядки.

4.7 Поиск ассоциативных правил

Ассоциативные правила позволяют находить закономерности между связанными событиями. Примером такого правила служит утверждение, что покупатель, приобретающий "Хлеб", приобретет и "Молоко". Впервые эта задача была предложена для поиска ассоциативных правил для нахождения типичных шаблонов покупок, совершаемых в супермаркетах, поэтому иногда ее еще называют анализом рыночной корзины (market basket analysis).

Пусть имеется база данных, состоящая из покупательских транзакций. Каждая транзакция – это набор товаров, купленных покупателем за один визит. Такую транзакцию еще называют рыночной корзиной. Целью анализа является установление следующих зависимостей: если в транзакции встретился некоторый набор элементов X , то на основании этого можно сделать вывод о том, что другой набор элементов Y также должен появиться в этой транзакции. Установление таких зависимостей дает нам возможность находить очень простые и интуитивно понятные правила.

Основными характеристиками таких правил являются поддержка и достоверность. Правило "Из X следует Y " имеет поддержку s , если $s\%$ транзакций из всего набора содержат наборы элементов X и Y . Достоверность правила показывает, какова вероятность того, что из X следует Y . Правило "Из X следует Y " справедливо с достоверностью c , если $c\%$ транзакций из всего множества, содержащих набор элементов X , также содержат набор / элементов Y . Покажем на конкретном примере: пусть 75% транзакций, содержащих хлеб, также содержат молоко, а 3% от общего числа всех транзакций содержат оба товара. 75% – это достоверность правила, а 3% -это поддержка.

Алгоритмы поиска ассоциативных правил предназначены для нахождения всех правил вида "из X следует Y ", причем поддержка и достоверность этих правил должны находиться в рамках некоторых наперед заданных границ, называемых соответственно минимальной и максимальной поддержкой и минимальной и максимальной достоверностью.

Границы значений параметров поддержки и достоверности выбираются таким образом, чтобы ограничить количество найденных правил. Если поддержка имеет большое значение, то алгоритмы будут находить правила, хорошо известные аналитикам или настолько очевидные, что нет никакого смысла проводить такой анализ. С другой стороны, низкое значение поддержки ведет к генерации огромного количества правил, что, конечно, требует существенных вычислительных ресурсов. Таким образом, необходимо найти

компромисс, обеспечивающий, во-первых, интересность правил и, во-вторых, их статистическую обоснованность.

4.7.1 Рассмотрим механизм поиска ассоциативных правил на примере данных о продажах товаров в некоторой торговой точке. Данные находятся в файле "Supermarket.txt". Импортируйте его. В таблице представлена информация по покупкам продуктов нескольких групп. Она имеет всего два поля "Номер чека" и "Товар". Необходимо решить задачу анализа потребительской корзины с целью последующего применения результатов для стимулирования продаж.

4.7.2 Для поиска ассоциативных правил запустим Мастер обработки. В нем выберем тип обработки "Ассоциативные правила". На втором шаге Мастера следует указать, какой столбец является идентификатором транзакции (чек), который должен быть дискретным, а какой элементом транзакции (товар).

4.7.3 Настроим параметры построения ассоциативных правил: минимальную и максимальную поддержку, минимальную и максимальную достоверность, а также максимальную мощность множества. Исходя из характера имеющихся данных, следует указать границы поддержки – 13% и 80% и достоверности 60% и 90%.

4.7.4 Запускаем процесс поиска ассоциативных правил. На экране отображается информация о количестве множеств и найденных правил, а также числе часто встречающихся множеств.

4.7.5 После завершения процесса поиска полученные результаты можно посмотреть, используя визуализаторы "Популярные наборы", "Правила", "Дерево правил", "Что-если".

4.7.5.1 Популярные наборы - это множества, состоящие из одного и более элементов, которые наиболее часто встречаются в транзакциях одновременно. На сколько часто встречается множество в исходном наборе транзакций, можно судить по поддержке. Данный визуализатор отображает множества в виде списка.

Само название визуализатора говорит о том, как применить данные результаты на практике. Получившиеся наборы товаров наиболее часто покупают в данной торговой точке, следовательно можно принимать решения о поставках товаров, их размещении и т.д.

№	Номер множества	ab. Элементы	Поддержка		S Мощность
			Кол-во	%	
1	1	ВАФЛИ	14	31,82	1
2	8	ВАФЛИ	6	13,64	2
		МЕД			
3	23	ВАФЛИ	6	13,64	3
		МЕД			
		ЧАЙ			
4	9	ВАФЛИ	10	22,73	2
		СУХАРИ			
5	24	ВАФЛИ	9	20,45	3
		СУХАРИ			
		ЧАЙ			
6	10	ВАФЛИ	13	29,55	2
		ЧАЙ			

4.7.6 Пусть необходимо проанализировать, что, возможно, забыл покупатель приобрести, если он уже взял вафли и мед. Для этого следует добавить в список условий эти товары (например, с помощью двойного щелчка мыши) и затем нажать на кнопку "Вычислить правила". При этом в списке следствий появятся товары, совместно приобретаемые с данными. В данном случае появятся "Сухари", "Чай", "Сухари и чай", т. е., может быть, покупатель забыл приобрести сухари, чай или и то и другое.

Элемент	Поддержка, %
ВАФЛИ	31,82
КЕТЧУПЫ, СОУСЫ...	52,27
МАКАРОННЫЕ ИЗ...	54,55
МЕД	50,00
СУХАРИ	31,82
СЫРЫ	43,18
ЧАЙ	75,00

Условие	
Элемент	Поддержка, %
ВАФЛИ	31,82
МЕД	50,00

Количество правил: 3

Следствие	Поддержка		Достоверность, %	Лифт
	Кол-во	%		
ЧАЙ	18	40,90	81,80	1,091
СУХАРИ	10	22,70	71,40	2,245
СУХАРИ И ЧАЙ	9	20,50	64,30	2,176

Как показал данный пример, результаты анализа можно применить и для сегментации покупателей по поведению при покупках, и для анализа предпочтений клиентов, и для планирования расположения товаров в супермаркетах, кросс-маркетинге. Предлагаемый набор визуализаторов позволяет эксперту найти интересные, необычные закономерности, понять, почему так происходит, и применить их на практике.

В данном примере найденные правила можно использовать для сегментации клиентов на два сегмента: клиенты, покупающие макаронные изделия и соусы к ним, и клиенты, покупающие все к чаю. В разрезе анализа предпочтений можно узнать, что наибольшей популярностью в данном магазине пользуются чай, мед, макаронные изделия, кетчупы, соусы и аджика. В разрезе размещения товаров в супермаркете можно применить результаты предыдущих двух анализов, т. е. располагать чай рядом с медом, а кетчупы, соусы и аджику рядом с макаронными изделиями и т.д.


4.8 Реализация алгоритма построения дерева решений

4.8.1 Теоретическая часть

Своевременная разработка и принятие правильного решения — это одна из главных задач работы управленческого персонала организации, т.к. необдуманное решение может дорого обойтись компании. Зачастую на практике результат одного решения заставляет нас принимать следующее решение и т. д. Когда же нужно принять несколько решений в условиях неопределенности, когда каждое решение зависит от исхода предыдущего, то применяют схему, называемую деревом решений.

Дерево решений — это графическое изображение процесса принятия решений, в котором отражены альтернативные решения, соответствующие вероятности, и выигрыши для любых комбинаций альтернатив.

Дерево решений представляет один из способов разбиения множества данных на классы или категории. Корень дерева неявно содержит все классифицируемые данные, а листья определенные классы после выполнения классификации. Промежуточные узлы дерева представляют пункты принятия решения о выборе.



Структура дерева решений

Построение дерева решений

Пусть нам задано некоторое обучающее множество T , содержащее объекты, каждый из которых характеризуется m атрибутами, причем один из них указывает на принадлежность объекта к определенному классу.

Пусть через $\{C_1, C_2, \dots, C_k\}$ обозначены классы, тогда существуют 3 ситуации:

- множество T содержит один или более примеров, относящихся к одному классу C_k . Тогда дерево решений для T – это лист, определяющий класс C_k ;
- множество T не содержит ни одного примера, т.е. пустое множество. Тогда это снова лист, и класс, ассоциированный с листом, выбирается из другого множества отличного от T , скажем, из множества, ассоциированного с родителем;
- множество T содержит примеры, относящиеся к разным классам. В этом случае следует разбить множество T на некоторые подмножества. Для этого выбирается один из признаков, имеющий два и более отличных друг от друга значений $O_1, O_2, \dots, O_n$. T разбивается на подмножества $T_1, T_2, \dots, T_n$, где каждое подмножество T_i содержит все примеры, имеющие значение O_i для выбранного признака. Эта процедура будет рекурсивно продолжаться до тех пор, пока конечное множество не будет состоять из примеров, относящихся к одному и тому же классу.

Вышеописанная процедура лежит в основе многих современных алгоритмов построения дерева решений, этот метод известен еще под названием «разделение и захват». Очевидно, что при использовании данной методики построение дерева решений будет происходить сверху вниз.

Области применения дерева решений

Дерево решений является прекрасным инструментом в системах поддержки принятия решений, интеллектуального анализа данных (DataMining). В областях, где высока цена ошибки, они послужат отличным подспорьем аналитика или руководителя.

Дерево решений успешно применяется для решения практических задач в следующих областях:

- Банковское дело. Оценка кредитоспособности клиентов банка при выдаче кредитов.
- Промышленность. Контроль качества продукции (выявление дефектов), испытания без разрушений (например, проверка качества сварки) и т.д.
- Медицина. Диагностика различных заболеваний.
- Молекулярная биология. Анализ строения аминокислот.

Это далеко не полный список областей, где можно использовать дерево решений, т.к. еще многие потенциальные области применения не исследованы.


4.8.1 Для загрузки данных примера импортируйте файл CreditSample.txt в АП «Deductor» с помощью мастера импорта. Все параметры импорта примите установленными по умолчанию. В окне выбора способа отображения данных выберите «Таблица», если он не выбран по умолчанию.

В результате в основном окне появится таблица, заполненная из указанного файла.


The screenshot shows the Deductor Studio Academic interface. The main window displays a table with 7 columns: Код, № Паспорта, ФИО, Адрес, Размер судды, руб, Срок судды, мес, and a final column for transaction descriptions. The table contains 24 rows of data. The left sidebar shows a project tree with 'Сценарии' and 'Текстовый файл (C:\Users\Королев...'.

Код	№ Паспорта	ФИО	Адрес	Размер судды, руб	Срок судды, мес	
1	0936-866096	1	1	10000	12	Покупка товаре
2	8355-512943	1	1	14000	12	Оплата за обра
3	8017-098471	1	1	25000	18	Оплата за обра
4	2762-945535	1	1	64000	48	Покупка и ремс
5	0459-997701	1	1	3500	6	Покупка товаре
6	6291-817248	1	1	8500	6	Иное
7	0094-883508	1	1	2500	6	Оплата услуг (н
8	6385-082612	1	1	27000	18	Иное
9	9290-732392	1	1	16500	12	Покупка и ремс
10	7022-736193	1	1	6500	6	Покупка товаре
11	3127-709332	1	1	22500	12	Покупка товаре
12	4179-171975	1	1	25000	18	Покупка и ремс
13	6099-152158	1	1	39000	12	Покупка товаре
14	3805-792726	1	1	16000	12	Покупка товаре
15	1352-805924	1	1	10000	6	Оплата услуг (н
16	2289-869384	1	1	9500	6	Покупка и ремс
17	2385-307290	1	1	49500	24	Оплата услуг (н
18	6504-055732	1	1	12500	6	Покупка и ремс
19	9188-250702	1	1	22000	12	Покупка товаре
20	7212-360647	1	1	30500	12	Покупка товаре
21	5137-102723	1	1	19500	12	Покупка товаре
22	6135-173882	1	1	13500	12	Покупка товаре
23	8094-918355	1	1	3500	6	Оплата услуг (н
24	6645-920913	1	1	31500	18	Оплата за обра

4.8.2 Запустите мастер обработки данных. В появившемся окне в разделе DataMining выберете метод обработки «Дерево решений» и нажмите «Далее».



4.8.3 На вкладке «Настройка значения столбцов» необходимо задать назначения столбцов данных. Почти все столбцы автоматически получили значение «Входные». Значение поля «Давать кредит», которое принимает только два значения «ИСТИНА» или «ЛОЖЬ», необходимо установить в «Выходное». Также необходимо обозначить столбцы «Код», «№ паспорта» и «Отраслевая принадлежность предприятия» как «Неиспользуемые» (так как значения этих столбцов уникальны, а это не позволит их классифицировать). Нажать кнопку «Далее»




4.8.4 Оставьте окно «Разбиение исходного набора данных на подмножества» без изменений и нажмите кнопку «Далее».

4.8.5 Следующий этап – настройка параметров обучения дерева решений. Необходимо учитывать, что чем больше значение параметра «Уровень доверия, используемый при отсечении узлов дерева», тем больше будет дерево решений в итоге. Нажимаем кнопку «Далее»


4.8.6 Способ построения выбираем «Автоматическое построение»

4.8.7 С помощью кнопки «Пуск» запускаем процесс построения дерева решений. По окончании процесса вы увидите график, отображающий уровень распознавания данных, количество узлов созданного дерева и правил, полученных в результате обработки. После выполнения процесса построения дерева решений, нажимаем кнопку «Далее»



4.8.8 В последующем окне выбора способа отображения данных выберите «Дерево решений». А в последнем окне мастера обработки, по желанию, укажите имя и метку. Нажмите «Готово»

4.8.9 Результатом всех вышеописанных действий будет построенное дерево решений, которое отобразится в основном окне программы. На основании этого метода можно ответить на вопрос «Давать ли человеку кредит и если да, то при каких условиях».



Из полученного дерева можно вывести правила выдачи кредитов. Например:

- Если срок проживания в данной местности меньше 6,5 лет, то кредит не давать.
- Если срок проживания в данной местности больше 6,5 лет, займ обеспечен, возраст больше 20,5 лет, не имеется недвижимость, но имеется банковский счет, то кредит давать.

4.9 Задание для самостоятельного выполнения

Выполните поиск ассоциативных правил для данных из файла «Чеки.txt». Границы поддержки и достоверности выберите самостоятельно.

5. Контрольные вопросы

- 5.1 Опишите возможности программы Deductor Studio
- 5.2 С помощью чего можно выполнять сглаживание и очистку от шумовой составляющей ряды данных?
- 5.3 Какие механизмы реализованы в Studio? Опишите два на ваш выбор
- 5.4 Что такое самоорганизующаяся карта Кохонена?
- 5.5 Для чего служат ассоциативные правила? Приведите пример.
- 5.6 Опишите структуру дерева решений