

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 18

Выполнил:
Цыпышев Т.А.
группа ИУ5-61Б

Проверил:
Гапанюк Ю.Е.

Дата: 11.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Задание:

Номер варианта: **18**

Номер задачи: **3**

Номер набора данных, указанного в задаче: **2**

(https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html#sklearn.datasets.load_wine)

Для студентов группы ИУ5-61Б - для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Задача №3.

Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака. Какие методы Вы использовали для решения задачи и почему?

1. Введение

В рамках рубежного контроля была проведена работа с набором данных Wine Dataset. Целью работы являлось масштабирование данных и преобразование категориальных признаков.

2. Описание исходных данных

Набор данных **Wine** из библиотеки `scikit-learn` содержит информацию о химическом составе вин из разных регионов, а также класс вина, который представляет собой категорию из трех классов (классов вин). Этот набор данных используется для классификации.

Данные состоят из 178 наблюдений и 13 признаков, которые представляют химические характеристики вина, такие как уровни различных химических компонентов, таких как алкоголь, пептиды, полифенолы и т.д.

3. Ход выполнения:

Решение

Замена числовых меток на категориальные значения

В оригинальном датасете `load_wine()` целевая переменная (`target`) представлена в виде чисел: 0, 1, 2. Эти значения соответствуют трем классам вина, но сами по себе они не несут смысловой нагрузки — они просто обозначают категории. Чтобы сделать данные подходящими для заание о преобразование категориальных признаков, мы заменили числовые метки на строковые названия вин Каберне Совиньон, Мерло, Пино Нуар.

```
[5] # Заменим числовые значения на строковые категории
target['target'] = target['target'].map({
    0: 'Каберне Совиньон',
    1: 'Мерло',
    2: 'Пино Нуар'
})

Python
```

```
[6] # Просмотрим первые несколько строк данных
data.head()

Python
```

```
...
   alcohol  malic_acid  ash  alkalinity_of_ash  magnesium  total_phenols  flavanoids  nonflavanoid_phenols  proanthocyanins  color_intensity  hue  od280/od315_of_diluted_wines  proline
0    14.23         1.71   2.43             15.6        127.0           2.80         3.06              0.28             2.29           5.64    1.04                  3.92    1065.0
1    13.20         1.78   2.14             11.2        100.0           2.65         2.76              0.26             1.28           4.38    1.05                  3.40    1050.0
2    13.16         2.36   2.67             18.6        101.0           2.80         3.24              0.30             2.81           5.68    1.03                  3.17    1185.0
3    14.37         1.95   2.50             16.8        113.0           3.85         3.49              0.24             2.18           7.80    0.86                  3.45    1480.0
4    13.24         2.59   2.87             21.0        118.0           2.80         2.69              0.39             1.82           4.32    1.04                  2.93    735.0
```

```
[7] target

Python
```

```
...
   target
0  Каберне Совиньон
1  Каберне Совиньон
2  Каберне Совиньон
3  Каберне Совиньон
4  Каберне Совиньон
...
173  Пино Нуар
174  Пино Нуар
175  Пино Нуар
176  Пино Нуар
177  Пино Нуар
178 rows x 1 columns
```

1. Масштабирование данных для одного признака:

Масштабирование данных позволит привести все данные к единому масштабу, что важно для некоторых алгоритмов машинного обучения (например, для методов, чувствительных к масштабу данных, таких как линейные модели, SVM, KNN).

Методы масштабирования:

- **Min-Max Scaling** (нормализация): масштабирует данные в диапазон от 0 до 1. Этот метод подходит, если нужно привести данные к одному масштабу, сохраняя пропорции между значениями.

$$X_{\text{scaled}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

```
[8] # Масштабирование признака 'alcohol' с использованием MinMaxScaler
scaler_minmax = MinMaxScaler()
data['alcohol_minmax_scaled'] = scaler_minmax.fit_transform(data[['alcohol']])

Python
```

```
[9] # Просмотрим результаты масштабирования
data[['alcohol', 'alcohol_minmax_scaled']].head()

Python
```

```
...
   alcohol  alcohol_minmax_scaled
0    14.23              0.842105
1    13.20              0.571053
2    13.16              0.560526
3    14.37              0.878947
4    13.24              0.581579
```

- **Standardization** (стандартизация): масштабирует данные так, чтобы они имели среднее значение 0 и стандартное отклонение 1. Этот метод полезен, если данные имеют распределение с выбросами.

$$X_{\text{scaled}} = \frac{X - \mu}{\sigma}$$

где (μ) — это среднее значение, а (σ) — стандартное отклонение.

```
[10] # Масштабирование признака 'alcohol' с использованием StandardScaler
scaler = StandardScaler()
data['alcohol_scaled'] = scaler.fit_transform(data[['alcohol']])

Python
```

```
[11] # Просмотрим результаты масштабирования
data[['alcohol', 'alcohol_scaled']].head()

Python
```

```
...
   alcohol  alcohol_scaled
0    14.23      1.518613
1    13.20      0.246290
2    13.16      0.196879
3    14.37      1.691550
4    13.24      0.295700
```

2. Преобразование категориальных признаков в количественные:

Для работы с категориальными признаками в машинном обучении часто используют методы, которые переводят их в числовые значения.

2.1. Label Encoding:

Label Encoding — это метод, при котором каждому уникальному значению категориального признака присваивается уникальный числовой код. Например, для признака "Цвет" можно присвоить:

- Красный → 0
- Зеленый → 1
- Синий → 2

Этот метод полезен, если категориальные данные имеют порядковую структуру. Однако если категория не имеет порядка, этот метод может внести нежелательную искаженность.

```
[12] # Для начала, преобразуем целевой признак в категориальный для примера
label_encoder = LabelEncoder()
target['target_label_encoded'] = label_encoder.fit_transform(target['target'])
Python
```

```
[13] # Посмотрим на результаты Label Encoding
target
Python
```

```
...
   target  target_label_encoded
0  Каберне Совиньон           0
1  Каберне Совиньон           0
2  Каберне Совиньон           0
3  Каберне Совиньон           0
4  Каберне Совиньон           0
...
173      Пино Нуар             2
174      Пино Нуар             2
175      Пино Нуар             2
176      Пино Нуар             2
177      Пино Нуар             2
178 rows x 2 columns
```

2.2. One-Hot Encoding:

One-Hot Encoding — это метод, при котором для каждого уникального значения категориального признака создается новый бинарный столбец. Если признак имеет 3 категории, то после one-hot encoding будет 3 новых столбца, где для каждой строки будет установлено значение 1 для соответствующей категории и 0 для других.

Пример: Для признака "Цвет" с уникальными значениями (Красный, Зеленый, Синий) после one-hot encoding получится:

- Красный → [1, 0, 0]
- Зеленый → [0, 1, 0]
- Синий → [0, 0, 1]

Этот метод лучше подходит для категориальных признаков без порядковой структуры.

```
[14] # Теперь применим OneHotEncoder
onehot_encoder = OneHotEncoder(sparse_output=False)
target_one_hot = onehot_encoder.fit_transform(target[['target']])
Python
```

```
[15] # Преобразуем результат в DataFrame и добавим к исходным данным
target_one_hot_df = pd.DataFrame(target_one_hot, columns=onehot_encoder.categories_[0])
target_with_onehot = pd.concat([target, target_one_hot_df], axis=1)
Python
```

```
[16] # Посмотрим на результаты One Hot Encoding
target_with_onehot
Python
```

```
...
   target target_label_encoded Каберне Совиньон Мерло Пино Нуар
0 Каберне Совиньон          0          1.0  0.0  0.0
1 Каберне Совиньон          0          1.0  0.0  0.0
2 Каберне Совиньон          0          1.0  0.0  0.0
3 Каберне Совиньон          0          1.0  0.0  0.0
4 Каберне Совиньон          0          1.0  0.0  0.0
...
173 Пино Нуар              2          0.0  0.0  1.0
174 Пино Нуар              2          0.0  0.0  1.0
175 Пино Нуар              2          0.0  0.0  1.0
176 Пино Нуар              2          0.0  0.0  1.0
177 Пино Нуар              2          0.0  0.0  1.0
178 rows x 5 columns
```


Дополнительное задание: Построение диаграммы рассеяния

Постройте диаграмму рассеяния (scatter plot) для двух произвольных колонок из набора данных "Wine" (данные о вине).

Цель: Визуализировать взаимосвязь между двумя признаками, выбрав любые два столбца из датасета.

```
[17] # Объединяем данные
data_with_target = data.copy()
data_with_target['target'] = target_with_onehot['target']

plt.figure(figsize=(8, 6))
sns.scatterplot(data=data_with_target, x='alcohol', y='malic_acid', hue='target', palette='Set2', alpha=0.7)
plt.title('Диаграмма рассеяния: Alcohol vs Malic Acid')
plt.xlabel('Alcohol')
plt.ylabel('Malic Acid')
plt.legend(title='Сорт вина')
plt.show()
Python
```



4. Используемые методы и причины их выбора

4.1. Масштабирование данных

Метод: Стандартизация (StandardScaler) или нормализация (MinMaxScaler)

Почему использовался:

- Многие модели машинного обучения (например, SVM, логистическая регрессия, KNN, нейронные сети) чувствительны к масштабу данных.
- Масштабирование помогает ускорить обучение и повысить точность за счёт более быстрой сходимости градиентных методов.

Преимущества:

- Улучшает производительность чувствительных к масштабу моделей.
- Предотвращает доминирование признаков с большим масштабом.

Недостатки:

- Не все модели требуют масштабирования (например, деревья решений и случайный лес).
- Требуется предварительного анализа, какой метод масштабирования подходит для конкретной задачи.

4.2. Label Encoding

Метод: Замена категориальных значений целыми числами (например, “низкий” → 0, “средний” → 1, “высокий” → 2)

Почему использовался:

- Подходит для признаков с естественным порядком (ordinal data).
- Упрощает данные, позволяя моделям учитывать порядок значений.

Преимущества:

- Простота реализации.
- Сохраняет порядок категорий, если он имеет смысл.

Недостатки:

- Может ввести в заблуждение модель, если порядок не имеет смысла (например, города или имена).
- Модели могут трактовать расстояние между категориями как равное, что не всегда верно.

4.3. One-Hot Encoding

Метод: Преобразование каждой категории в отдельный бинарный столбец.

Почему использовался:

- Идеален для номинативных категориальных признаков (например, "цвет", "тип продукта").

Преимущества:

- Избегает ложной интерпретации порядка между категориями.
- Работает корректно с большинством моделей.

Недостатки:

- Увеличивает размерность данных (особенно при большом количестве уникальных категорий).
- Может привести к разреженным матрицам (sparse data).

5. Выводы

- Для масштабирования данных можно использовать стандартизацию или нормализацию в зависимости от задачи.
- Для преобразования категориальных признаков в количественные можно использовать два метода: Label Encoding и One-Hot Encoding в зависимости от порядка категорий.

Оба этих этапа — масштабирование и преобразование категориальных признаков — являются важными шагами предобработки данных перед применением моделей машинного обучения.