

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №2

«Методы построения моделей машинного обучения.»

Вариант № 18

Выполнил:
Цыпышев Т.А.
группа ИУ5-61Б

Проверил:
Гапанюк Ю.Е.

Дата: 11.06.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

1. Задание

Группа: ИУ5-61Б

Вариант: 18

Для заданного набора данных "World Happiness Index and Inflation Dataset" необходимо было построить модели регрессии для предсказания индекса счастья (столбец '**Score**'). В соответствии с вариантом задания для группы ИУ5-61Б были выбраны следующие методы:

1. **Метод №1:** Линейная регрессия
2. **Метод №2:** Случайный лес

В ходе работы была выполнена предобработка данных, включающая загрузку, анализ, заполнение пропусков и кодирование категориальных признаков. Качество построенных моделей оценивалось с использованием стандартных метрик для задач регрессии.

2. Предобработка данных

Загрузка и первичный анализ

Данные были загружены с использованием библиотеки kagglehub. Первичный анализ показал наличие пропущенных значений в нескольких столбцах, что потребовало дальнейшей обработки.

Обработка пропущенных значений

Пропуски в данных обрабатывались следующим образом:

- **Числовые признаки:** Пропущенные значения были заменены **медианой** соответствующего столбца. Медиана была выбрана вместо среднего, так как она менее чувствительна к выбросам.
- **Категориальные признаки:** Пропуски заполнялись **наиболее часто встречающимся значением** (модой), что является стандартным подходом для данного типа данных.

Кодирование категориальных признаков

Категориальные признаки, такие как название страны, были преобразованы в численный формат с помощью **One-Hot Encoding**. Этот метод создает новые бинарные столбцы для каждой категории, что позволяет моделям машинного

обучения корректно работать с этими данными, не внося ложной порядковой зависимости.

Масштабирование и разделение данных

Числовые признаки были масштабированы с использованием StandardScaler для приведения их к единому масштабу, что улучшает сходимость и производительность многих алгоритмов. После всех преобразований данные были разделены на **обучающую (80%)** и **тестовую (20%)** выборки для обучения и последующей оценки моделей.

3. Построение и оценка моделей

Для объединения всех шагов предобработки (импутация, кодирование, масштабирование) и обучения модели был использован конвейер Pipeline из scikit-learn. Это обеспечивает удобство, воспроизводимость и предотвращает утечку данных из тестовой выборки в обучающую.

Для оценки качества моделей были выбраны следующие метрики:

- **Средняя абсолютная ошибка (MAE):** Показывает среднее абсолютное отклонение предсказаний от истинных значений. Легко интерпретируется, так как измеряется в тех же единицах, что и целевая переменная.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- **Корень из среднеквадратичной ошибки (RMSE):** Также измеряется в единицах целевой переменной, но сильнее штрафует за большие ошибки по сравнению с MAE.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

- **Коэффициент детерминации (R² Score):** Показывает долю дисперсии целевой переменной, которую способна объяснить модель. Значение, близкое к 1, указывает на высокое качество модели.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Эти метрики были выбраны, так как они комплексно оценивают точность и объясняющую способность регрессионных моделей.


Метод №1: Линейная регрессия

Модель линейной регрессии была обучена на подготовленных данных.

Результаты оценки на тестовой выборке следующие:

- **MAE:** 0.3541
- **MSE:** 0.2227
- **RMSE:** 0.4719
- **R² Score:** 0.8258

Визуализация предсказаний показывает, что точки в основном сгруппированы вокруг идеальной диагональной линии, что говорит о хорошем качестве модели.




Метод №2: Случайный лес (Random Forest)

Модель случайного леса, состоящая из 100 деревьев, была обучена на тех же данных. Результаты оценки на тестовой выборке:

- **MAE:** 0.3662
- **MSE:** 0.2332
- **RMSE:** 0.4829
- **R² Score:** 0.8176

Визуально предсказания также выглядят хорошо, но наблюдается чуть большее рассеяние точек по сравнению с линейной регрессией.






4. Сравнение моделей и выводы

Для наглядного сравнения сведем полученные метрики в таблицу и построим диаграммы.

Модель	MAE	MSE	RMS E	R2 Score

Линейная регрессия	0.3541	0.2227	0.4719	0.8258
Случайный лес	0.3662	0.2332	0.4829	0.8176





5. Выводы

На основе проведенного анализа можно сделать следующие выводы:

1. **Линейная регрессия** показала **лучшие результаты** по всем ключевым метрикам. Значения MAE и RMSE у нее ниже, а R^2 Score — выше. Это означает, что предсказания линейной регрессии в среднем ближе к фактическим значениям, и модель объясняет большую долю изменчивости индекса счастья (82.6%) по сравнению со случайным лесом (81.8%).
2. **Случайный лес**, будучи более сложной моделью, уступил линейной регрессии. Это может указывать на то, что зависимости в данном наборе данных достаточно **линейны**, и усложнение модели не привело к улучшению качества, а, возможно, даже вызвало небольшое переобучение или потребовало бы более тщательной настройки гиперпараметров.
3. **Итоговый выбор:** Для задачи предсказания индекса счастья на данном наборе данных **модель Линейной регрессии является более предпочтительной**, так как она обеспечивает более высокую точность при меньшей сложности.